


¿QUÉ TAN “ALEATORIOS” SON TUS DATOS FALTANTES?

APRENDE A DIFERENCIAR MCAR, MAR Y MNAR EN TU EDA.



LOS 3 TIPOS DE DATOS FALTANTES EXPLICADOS

Este es un dataset sintético (creado artificialmente) que simula un portafolio de 1,000 clientes de una entidad financiera, como un banco o una plataforma de inversión. 📊

El propósito principal de este dataset es educativo: fue diseñado específicamente para ilustrar los tres tipos de datos faltantes (MCAR, MAR y MNAR) que se discuten en ciencia de datos.

Descripción de las Variables y sus Rangos:

Cliente_ID

Qué representa: Es un identificador numérico único para cada cliente. Actúa como la "llave primaria" de la tabla.

Rango: Números enteros (int) desde 1001 hasta 2000.

Datos Faltantes: Ninguno.

Edad

Qué representa: La edad del cliente en años.

Rango: Números enteros (int) generados aleatoriamente entre 20 y 69.

Datos Faltantes: Ninguno.

Tipo_Cuenta

Qué representa: La categoría o nivel de la cuenta que el cliente tiene en la institución. Esta es una variable categórica.

Rango (Valores posibles): 'Básica', 'Premium', o 'Inversión'.

Datos Faltantes: Ninguno. (Esta variable se usa para causar los datos faltantes en Ingreso_Anual).

Ingreso_Anual

Qué representa: El ingreso anual reportado por el cliente, en moneda.

Rango: Números decimales (float). El rango depende del Tipo_Cuenta para hacerlo más realista (ej. 'Básica' tiene ingresos entre 20,000-50,000, mientras 'Inversión' tiene entre 150,000-300,000).

Datos Faltantes: Sí (MAR - Faltante al Azar). La probabilidad de que este dato falte depende de la columna Tipo_Cuenta. Creamos la regla de que las cuentas 'Básica' omiten este dato mucho más (40% de las veces) que las cuentas 'Inversión' (solo 2%).

Evaluacion_Riesgo

Qué representa: Un "score" o puntaje numérico que evalúa el riesgo del cliente (similar a un puntaje de buró de crédito). Un número más alto significa más riesgo.

Rango: Números decimales (float) entre 300 (riesgo muy bajo) y 850 (riesgo muy alto).

Datos Faltantes: Sí (MNAR - Faltante No al Azar). Este es el caso más complejo. La probabilidad de que este dato falte depende de su propio valor. Configuramos que los clientes con puntajes muy altos (ej. > 750) tengan una alta probabilidad (50%) de no reportar su puntaje, mientras que los clientes de bajo riesgo casi siempre lo reportan (falta solo 5% de las veces).

Ultima_Conexion_Region

Qué representa: La región geográfica desde donde el cliente se conectó por última vez. Esta es una variable categórica.

Rango (Valores posibles): 'Norte', 'Sur', 'Centro', 'Este'.

Datos Faltantes: Sí (MCAR - Faltante Completamente al Azar). Un pequeño porcentaje (5%) de estos datos falta de forma totalmente aleatoria. Esto simula un error técnico o un fallo en el servidor que no tiene relación con el cliente, su cuenta ni ninguna otra variable.

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import matplotlib
```

```

# CARGA DEL DATA SET Y EDA BASICO # Nombre del
archivo CSV
file_name = 'dataset_sintetico_app_financiera.csv'
try:

    # Cargar el dataset
    df = pd.read_csv(file_name)

    print(f"Análisis de '{file_name}'")

    # .info() nos da un resumen de tipos de datos y nulos
    print("\nFuncion .info()")
    df.info()

    # .describe() para estadísticas de variables numéricas
    print("\nFuncion describe()")
    print(df.describe())

    # .describe(include='object') para estadísticas de variables
    categóricas
    print("\nFuncion .describe() (Categórico)")
    print(df.describe(include='object'))

    # Conteo específico de nulos por columna
    print("\nFuncion Conteo de Nulos (isnull().sum())")
    missing_sum = df.isnull().sum()
    print(missing_sum)

    # Generación de la Gráfica

    print("\nGeneracion de gráfica de datos faltantes")

    # 1. Preparar los datos para la gráfica
    # Contamos los datos presentes
    present_counts = df.notnull().sum()

    # Creamos un nuevo DataFrame para la gráfica
    plot_df = pd.DataFrame({
        'Presente': present_counts,
        'Faltante': missing_sum
    })

    # Ordenar por total de faltantes para una mejor visualización
    plot_df = plot_df.sort_values(by='Faltante', ascending=True)

    # 2. Crear la gráfica de barras apiladas horizontal
    colors = ['skyblue', 'salmon'] # Celeste para 'Presente', Salmón
    para 'Faltante'

    # Crear la figura y los ejes

```

```

fig, ax = plt.subplots(figsize=(12, 7))

# Generar la gráfica
plot_df.plot(
    kind='barh',
    stacked=True,
    color=colors,
    ax=ax
)

# Configurar títulos y etiquetas
ax.set_title('Conteo de Datos Presentes vs. Faltantes por
Variable', fontsize=16)
ax.set_xlabel('Conteo de Observaciones (Total = 1000)',
fontsize=12)
ax.set_ylabel('Variable', fontsize=12)
# Configurar leyenda
ax.legend(title='Estado', loc='lower right')
# Añadir cuadrícula para legibilidad
ax.grid(axis='x', linestyle='--', alpha=0.7)
# Añadir los valores numéricos a las barras
for container in ax.containers:

    for patch in container.patches:
        width = patch.get_width()
(hay datos) if width > 0: # Sólo añadir texto si la barra tiene ancho
            ax.text(patch.get_x() + width/2., patch.get_y() +
patch.get_height()/2.,
                    '%d' % int(width),
                    ha='center', va='center',
                    color='black', fontsize=10)

# Optimizar el layout
plt.tight_layout()
# Mostrar la gráfica
plt.show()

except FileNotFoundError:
    print(f"Error: No se encontró el archivo '{file_name}'.")
except Exception as e:
    print(f"Ocurrió un error inesperado: {e}")
Análisis de 'dataset_sintetico_app_finanicera.csv'

Funcion .info()
<class 'pandas.core.frame.DataFrame'>

```

RangelIndex: 1000 entries, 0 to 999

Data columns (total 6 columns):

Column	-----	Cliente_ID	Non-Null	Count	---	Dtype	--
Edad		Tipo_Cuenta	non-null	1000		int64	
Ultima_Conexion_Region			non-null	1000		object	
Ingreso_Anual			non-null	950	non-null	float64	
Evaluación_Riesgo			859	non-null		float64	

--- 0 1 2 3 4 5 dtypes: float64(2), int64(2),
object(2) memory usage: 47.0+ KB

Funcion describe()

	Cliente_ID	Edad	Ingreso_Anual	Evaluacion_Riesgo
count	1000.000000	1000.000000	758.000000	859.000000
mean	1500.500000	44.830000	112646.803430	556.072177
std	288.819436	14.346809	77596.262953	146.221443
min	1001.000000	20.000000	20053.000000	300.000000
25%	1250.750000	33.000000	41345.000000	435.500000
50%	1500.500000	45.000000	100958.500000	552.000000
75%	1750.250000	56.000000	150708.750000	679.500000
max	2000.000000	69.000000	299673.000000	849.000000

Funcion .describe() (Categórico)

	Tipo_Cuenta	Ultima_Conexion_Region
count	1000	950
unique	3	4
top	basica	centro
freq	477	285

Funcion Conteo de Nulos (isnull().sum())

Cliente_ID	0
Edad	0
Tipo_Cuenta	0
Ultima_Conexion_Region	50
Ingreso_Anual	242
Evaluación_Riesgo	141

dtype: int64

Generacion de gráfica de datos faltantes

